

# SM II Abgabe 2

Abigail Alexander

12.November 2018

## Aufgabe 1

Wozu werden Standardisierungen durchgeführt und wie wird dabei vorgegangen? Erläutern Sie zudem exemplarisch wozu  $b^*$  benutzt wird und wie man diesen interpretiert!

$$b^* = b * \frac{s_x}{s_y}$$

Wenn Regressionskoeffizienten standardisiert sind, sind sie mit einander vergleichbar innerhalb einer Regressionsanalyse unter gewissen Bindungen. Die unterschiedlichen Skalen werden standardisiert und haben einen Mittelwert von 0 und Standardabweichung von 1. Der standardisierte Regressionskoeffizient ist gleich dem unstandardisierten Regressionskoeffizient multipliziert mit der Standardabweichung der unabhängigen Variablen und dividiert durch die Standardabweichung der abhängigen Variablen.

## Aufgabe 2

Führen Sie eine z-Standardisierung für die Originalaltersvariable (`alter_z`) und die auf Null gesetzte Altersvariable (`alter_0z`) sowie für "unsere" Bildungsvariable (0 bis 4) und das Einkommen. [Daten: ALLBUS 2014]

```
allb_sub<-allb_sub %>%
  mutate(alter_z = scale(alter, center = F, scale = T)) %>%
  mutate(alter_0z = scale(alter0, center = F, scale = T)) %>%
  mutate(bildung_z = scale(bildung, center = F, scale = T)) %>%
  mutate(einkommen_z = scale(einkommen, center = F, scale = T))
allb_sub

## # A tibble: 3,471 x 11
##   alter bildung geschl einkommen alter0 bildung_rec geschl_rec alter_z
##   <dbl> <dbl>+1 <dbl>+ <dbl>+1+1 <dbl>+ <dbl> <dbl> <dbl>
## 1 33     5      2      14      15      4      0  0.629
## 2 50     3      2      " 9"    32      2      0  0.953
## 3 56     3      1      17      38      2      1  1.07
## 4 61     3      1      " 8"    43      2      1  1.16
## 5 59     3      2      " 9"    41      2      0  1.12
## 6 56     3      1      21      38      2      1  1.07
## 7 66     2      1      12      48      1      1  1.26
## 8 25     5      2      NA      " 7"    4      0  0.477
## 9 58     4      1      13      40      3      1  1.11
## 10 53     3      1      19      35      2      1  1.01
## # ... with 3,461 more rows, and 3 more variables: alter_0z <dbl>,
## #   bildung_z <dbl>, einkommen_z <dbl>
```

## Aufgabe 2a

Vergleichen Sie die Zahlenwerte, Mean und die Standardabweichung von `alter_z` und `alter_0z` und erklären Sie Ihre "Beobachtung".

```
allb_sub %>%
  select(alter_z, alter_0z) %>%
  describe() %>%
  select(-vars, -range, -trimmed, -mad, -skew, -kurtosis, -se) %>%
  kable()
```

	n	mean	sd	median	min
alter_z	3468	0.9425297	0.3337386	0.9531996	0.3431519
alter_0z	3468	0.8735960	0.4864256	0.8891475	0.0000000
Wie erwartet ist die Mean-Werte höher für die Variable alter_z als die der Variable alter_0z, da ihre min Wert					

## Aufgabe 2b

Führen Sie eine Regression von Einkommen auf `alter_0` und `bildung` (Modell 1) und eine Regression von `einkommen_z` auf `alter_0z` und `bildung_z` (Modell 2) durch und vergleichen Sie die b-Koeffizienten.

```
mod1 <- lm(einkommen ~ alter0 + bildung_rec, data = allb_sub)
mod2 <- lm(einkommen_z ~ alter_0z + bildung_z, data = allb_sub)
screenreg(list(mod1, mod2))
```

```
##
## =====
##              Model 1      Model 2
## -----
## (Intercept)    7.17 ***    0.51 ***
##               (0.28)      (0.03)
## alter0         0.04 ***
##               (0.01)
## bildung_rec    1.20 ***
##               (0.07)
## alter_0z              0.12 ***
##                   (0.02)
## bildung_z              0.32 ***
##                   (0.02)
## -----
## R^2            0.08        0.07
## Adj. R^2       0.08        0.07
## Num. obs.      3039        3062
## RMSE           4.74        0.39
## =====
## *** p < 0.001, ** p < 0.01, * p < 0.05
```

Im Modell 2 ist der b-koeffizient für die Variable `alter` grösser als im Modell 1, aber die für `Bildung` ist kleiner. Die Standardabweichungen sind im Modell 2 gleich, obwohl im Modell 1 sind die unterschiedlich. In beiden Modellen ist der b-koeffizient für `bildung` grösser als für `alter`. Eine Schlussfolgerung wäre, die Variable `bildung` erklärt die Variation von Einkommen besser als die Variable `alter`.

## Aufgabe 2c

Wie erklären Sie die Werte  $b$  und  $b^*$  in Modell 2? TIPP: Verwenden Sie bei Modell 2 das z-transformierte Einkommen als abhängige Variable.

## Aufgabe 3

Erstellen Sie ein multivariates Regressionsmodell mit  $Y$ =Einkommen. Versuchen Sie dabei den  $R^2$ -Wert so groß wie nur irgendwie möglich zu bekommen. Jeder schmutzige Trick der Sozialforschung ist erlaubt (und in diesem Fall erwünscht).

- Einzige Einschränkung: Keine Regression von  $Y$  auf  $Y$ .

Tipp: Mit `binocular` könnt ihr den Datensatz nach relevanten Variablen durchsuchen :)

```
mod1 <- lm(V420 ~ V83 + V84 + V86 + V81 + V83*V84 + V135 + V136 + V135*V136 + V493 + V529 + V530 + V529*V530)
screenreg(list(mod1))
```

```
##
## =====
##              Model 1
## -----
## (Intercept)  -2478.95
##              (2602.19)
## V83           1.01
##              (1.22)
## V84           0.39
##              (17.22)
## V86           0.87
##              (0.60)
## V81          -3.59 **
##              (1.21)
## V135          0.33
##              (0.55)
## V136         -1.62
##              (1.75)
## V493          0.00 ***
##              (0.00)
## V529         215.01
##              (400.08)
## V530          0.23
##              (0.39)
## V83:V84       0.00
##              (0.01)
## V135:V136     -0.02
##              (0.05)
## V529:V530    -0.11
##              (0.20)
## -----
## R^2           0.57
## Adj. R^2      0.45
## Num. obs.     54
## RMSE          3.86
## =====
## *** p < 0.001, ** p < 0.01, * p < 0.05
```