

1. Wozu werden Standardisierungen durchgeführt und wie wird dabei vorgegangen? Erläutern Sie exemplarisch wozu  $b^*$  benutzt wird und wie man diesen inhaltlich interpretiert!

Standardisierungen beziehen sich auf die empirische Rohwerte der X- und Y- Variable innerhalb eines Modell. Die Variablen werden durch die Standardisierung auf einer gleichen Skala zugeordnet.

Bei einer Standardisierung werden die arithmetische Mittelwerte aller empirischen Variablenwerte berechnet. Folgedessen werden die jeweiligen Mittelwerte von jedem einzelnen Variablenwert subtrahiert. Ein weiterer Schritt der Standardisierung ist die Standardabweichung (Wurzel aus der Varianz) für jeder erhaltene Wert durchzuführen:  $S_x = \sqrt{(\sum (x_i - \bar{x})^2) / N}$ .

Aus der Standardisierung kommen standardisierte Werte, die sich in den Wertebereich -1 und +1 befinden, die die Gleichung und Berechnung des standardisierten Regressionskoeffizient ermöglichen:

$b^* = b \cdot S_z / S_y$ . Die Standardisierung zuschreibt einem jeden Variablenwert ein fester Platz auf einer Standardskala. Das heisst, dass die Werte nicht mehr abhängig von Wertebereich oder der Skalenbreite sind (was für unstandardisierten Regressionsschätzung nicht der Fall ist). Da alle Koeffizienten ( $b^*$ ) auf einer gleichen Skala zugeordnet werden, werden sie miteinander vergleichbar bzw.  $b^*$  wird benutzt um die Effektstärke von unterschiedlichen skalierten X-Variablen in einer Schätzung zu vergleichen. Die inhaltliche Interpretation soll heissen, dass wenn sich X um eine Einheit verändert, ändert sich Y um  $b^*$ -Einheiten.

**2. Führen Sie eine z-Standardisierung für die Originalaltersvariable (alter\_z) und die auf Nullgesetzte Altersvariable (alter\_0z) sowie für „unsere“ Bildungsvariable (0 bis 4). [Daten: ALLBUS2014]**

**a) Vergleichen Sie die Zahlenwerte, Mean und die Standardabweichung von alter\_z und alter\_0z und erklären Sie Ihre „Beobachtung“.**

Das Vergleichen der Zahlenwerte Mean und Standardabweichung ergibt, dass Mean in beide Modelle gleich 0 und die Standardabweichung (SD) gleich 1 ist. Dieses lässt sich dadurch erklären, dass die X-Variablen aus einer z-Standardisierung entstehen. Doch die standardisierten Koeffizienten bezeichnen das Ausmaß der Veränderung einer abhängigen Y-Variablen auf einer Standardskala von einem Mittelwert, der gleich 0 ist, und die eine Standardabweichung, die gleich 1 ist, hat.

**b) Führen Sie eine Regression von Einkommen auf alter\_0 und bildung (Modell 1) und eine Regression von einkommen\_z auf alter\_0z und bildung\_z (Modell 2) durch und vergleichen Sie die b-Koeffizienten.**

	Model 1	Model 2
(Intercept)	6.21 *** (0.34)	0.00 (0.02)
alter0	0.04 *** (0.01)	
bildung	1.09 *** (0.07)	
alter_0z		0.14 *** (0.02)
bildung_z		0.29 *** (0.02)
R <sup>2</sup>	0.07	0.08
Adj. R <sup>2</sup>	0.07	0.08
Num. obs.	3062	3039
RMSE	4.78	0.96

\*\*\* p < 0.001, \*\* p < 0.01, \* p < 0.05

Der Vergleich von den zwei Regressionsmodellen führt zu der Schlussfolgerung, dass die b-Koeffizienten in den zwei Modellen nicht die gleichen Werte haben, aber die Einflussrichtung und die Signifikanz bleibt unverändert. Die Veränderung zwischen dem nicht standardisierten Koeffizienten des Alters und dem standardisierten Koeffizienten ist, dass die Werte des Alters größer werden: von 4% zu 14%. Anders formuliert zeigt der standardisierte Koeffizient, dass Alter mehr Einflussstärke im Modell 2 hat.

Die Standardisierung der Variable Bildung ändert den Koeffizienten ziemlich viel, da er größer als 1 war. Da die Werte von standardisierten Koeffizienten sich zwischen -1 und +1 befinden, war eine Veränderung zu erwarten. Der Einfluss von Bildung sinkt von 1,09 auf 0,29.

Dabei ist es wichtig zu sehen, dass die zwei Variablen Alter und Bildung im Modell 2 weniger Abstand in deren Einflussstärke haben auf Einkommen.

**c) Wie erklären Sie die Werte b und "b<sup>z</sup>" in Modell 2? TIPP: Verwenden Sie bei Modell 2 das z-transformierte Einkommen als abhängige Variable**

**3. Erstellen Sie ein multivariates Regressionsmodell mit Y=Einkommen. Versuchen Sie dabei den R<sup>2</sup>-Wert so groß wie nur irgendwie möglich zu bekommen. Jeder schmutzige Trick der Sozialforschung ist erlaubt (und in diesem Fall erwünscht). Fügen Sie die entsprechenden Teile des SPSS-Outputs in Ihre Abgabe ein.**

	Model 1	Model 2	Model 3	Model 4	Model 5	Model 6	Model 7
(Intercept)	11.14 *** (0.09)	11.17 *** (0.09)	16.42 *** (0.25)	16.16 *** (0.32)	16.16 *** (0.32)	13.89 *** (0.30)	0.00 *** (0.00)
alter_0z	0.34 *** (0.09)	0.68 *** (0.09)	0.70 *** (0.08)	0.32 ** (0.10)	0.32 ** (0.10)	0.12 (0.09)	0.00 (0.00)
bildung_z		1.45 *** (0.09)	1.51 *** (0.08)	1.31 *** (0.10)	1.31 *** (0.10)	1.11 *** (0.09)	0.00 * (0.00)
geschl			-3.56 *** (0.16)	-4.28 *** (0.19)	-4.28 *** (0.19)	-3.10 *** (0.17)	-0.00 ** (0.00)
V489				0.00 *** (0.00)	0.00 *** (0.00)	-0.00 ** (0.00)	-0.00 (0.00)
V419						0.00 *** (0.00)	0.00 *** (0.00)
V418							1.00 *** (0.00)
R^2	0.00	0.08	0.21	0.36	0.36	0.50	1.00
Adj. R^2	0.00	0.08	0.21	0.36	0.36	0.50	1.00
Num. obs.	3064	3039	3039	1904	1904	1904	18
RMSE	4.95	4.74	4.40	4.03	4.03	3.57	0.00

\*\*\* p < 0.001, \*\* p < 0.01, \* p < 0.05